

商务印尼语谈判演练智能体评测方案

版本 v1.0 | 2026 年 9 月 | 配合《商务印尼语谈判演练智能体产品需求文档》v1.0 使用

本文档说明如何判断这个智能体是否有效。评测回答三个问题：产品检索出的语料是否适用，产品给出的诊断是否正确，学习者是否因此获得了可衡量的提升。文档给出指标定义与计算方式、评分量表、黄金评测集的构建方法、对照实验与用户测试流程，并说明在现有样本规模下结论可以覆盖到什么范围。

1 评测框架

评测分三层进行。检索层和生成层可以用人工标准答案给出准确率，效果层在现有条件下只能给出初步证据，报告中必须区分这两种证据强度。

层级	评测对象	主要指标	方法
检索层	语料召回与阶段过滤	检索命中率、阶段过滤准确率	黄金评测集
生成层	角色回应、诊断、参考表达	诊断命中率与误报率、引用有效率、量表评分	黄金评测集与盲评
效果层	学习者的表达与使用意愿	前后测得分、会话完成率、使用意愿	用户测试

2 待验证假设

编号	假设	验证方式	通过标准
H1	语料增强的反馈在商务得体性与地道度上优于通用大模型	固定输入的对照实验	两个维度均值差不低于 0.5，配对检验 p 小于 0.05
H2	阶段状态机提高谈判任务完成度	用户测试中的完成率	会话完成率不低于 60%
H3	学习者能感知语料溯源的价值	问卷与出声思维记录	认同比例不低于 70%
H4	诊断结果可信	黄金评测集	误报率不高于 10%，命中率不低于 70%

3 指标与计算方式

指标	计算方式	目标
检索命中率 (Recall@3)	前三条检索结果中至少一条被判为适用的任务比例	不低于 0.80
阶段过滤准确率	返回语料的阶段标签与当前阶段一致的比例	不低于 0.95
引用有效率	引用的语料确实来自语料库，且与当前语境相关	不低于 0.90
诊断命中率	与专家标注一致的诊断条目占全部应报偏误的比例	不低于 0.70

指标	计算方式	目标
诊断误报率	系统报出偏误、但专家判定无需修改的条目占比	不高于 0.10
表达质量均分	四维量表得分均值	不低于 3.0 分
会话完成率	完成全部阶段并生成复盘报告的会话占比	不低于 0.60

4 量表设计

4.1 学习者表达质量量表

评分对象是学习者的单轮印尼语输出，四个维度各分为四级。评分依据是专家判断与语料对照，不参考评分者对学习者的印象。

维度	4 分	3 分	2 分	1 分
语法与词形准确性	无形态或句法错误	个别不地道，但无语法错误	存在明显偏误，需要修改	错误影响理解
商务得体性	完全符合该阶段的商务惯例与信息要求	基本符合，个别信息不完整	与阶段惯例不符，需要重写	违反商务惯例或无法推进任务
礼貌与语用策略	称谓与间接表达恰当，顾及对方面子	整体礼貌，个别表达偏直接	出现直接否定或命令式表达	明显失礼
任务推进有效性	明确推进目标并给出必要信息	有所推进，但信息不完整	未推进或重复上一轮	使谈判倒退或造成误解

评分边界规则：只包含“好的”或“我同意”这类没有实质信息的回应，任务推进维度记 1 分；语法正确但完全没有商务内容的句子，商务得体性记 1 分。完整的边界案例见附录 A。

4.2 系统输出质量评判

评判项目	评判方式	判定结果
角色回应是否契合当前阶段	是否落在本阶段应完成的任务范围内	契合、部分契合、不契合
引用的语料是否来自语料库	与语料库条目逐条核对	真实、无法核对、虚构
引用的语料是否与语境相关	专家判断	适用、勉强适用、不适用
诊断是否附有语料佐证	是否给出可以核对的语料	有、无
参考表达是否优于学习者原句	专家判断	更好、相当、更差

4.3 诊断准确性判定

判定	定义	计入
命中	系统指出的偏误类型与专家一致，且位置正确	真阳性

判定	定义	计入
部分命中	类型正确但解释不准确，或指出位置有偏差	按 0.5 折算
漏报	专家判定存在偏误，系统未指出	假阴性
误报	专家判定无需修改，系统仍然指出偏误	假阳性

误报率的权重高于命中率。学习者对错误诊断的容忍度很低，一次错误判断就会影响对整个产品的信任，因此误报率不高于 10% 是硬性门槛，命中率可以在后续版本中逐步提高。

5 黄金评测集

5.1 规模与构成

部分	规模	用途
学习者产出句	120 至 150 条	诊断准确性、量表校准
检索查询	30 个阶段化任务	检索命中率与阶段过滤准确率
系统输出样本	40 至 60 条	生成层的盲评与引用核查

学习者产出句有三个来源：用户测试中收集的作答、印尼语专业学生作业或练习的转换、按阶段任务定向征集的句子。每一条都记录来源、学习者背景与所属阶段。

5.2 抽样策略

- 按 negotiation_stage 分层，每个阶段不少于 15 条。
- 覆盖五类偏误：词缀与词形、被动结构、敬称与称谓、礼貌与语气策略、固定搭配与术语，每类不少于 15 条。
- 每个阶段保留至少 5 条没有偏误的句子，专门用于检测误报。
- 保留一部分口语化、碎片化的真实输入，不做润色，因为真实学习者不会写出完整的书面句。

5.3 构建流程

1. 收集原始句子并编号，记录来源、学习者背景与所属阶段。
2. 两名标注者独立判断是否存在偏误、偏误类型与修改建议，互不通气。
3. 计算一致性；不一致的条目交由第三名标注者裁决。
4. 形成标准答案：是否存在偏误、偏误类型、是否必须修改、参考表达、四维得分。
5. 冻结版本并记录版本号，此后的任何修改都保留变更记录。
6. 用冻结版本评测系统，评测期间不再改动标准答案。

5.4 标注一致性

用 Cohen's Kappa 衡量“是否存在偏误”这一二分类判断的一致性，目标不低于 0.70。低于 0.70 时先修订标注指南再重新标注，不进入评测环节。量表四维评分用组内相关系数衡量评分者一致性。

5.5 条目数据结构

字段	说明	示例
item_id	条目编号	L-0137
stage	所属阶段	议价
learner_text	学习者原句	Harga terlalu mahal, saya tidak bisa terima.
error_present	是否存在偏误	是
error_type	偏误类型	词形, 语气策略
severity	是否必须修改	是
reference	参考表达	Mohon maaf, harga tersebut masih di atas anggaran kami. Apakah ada kemungkinan penyesuaian?
scores	四维得分	语法 2, 得体性 2, 礼貌 2, 任务推进 3
note	备注	需要向对方说明预算限制

没有偏误的条目同样入库，例如：Saya sudah menerima penawaran Bapak. Apakah harga tersebut masih berlaku untuk pengiriman bulan depan? 这条句子的 error_present 记为否，四维得分均为 4，用于检验系统是否会产生误报。上面的印尼语仅用于说明数据结构，正式建库时以真实学习者语料替换。

6 对照实验

6.1 设计

用固定输入消除学习者个体差异。取 20 条来自黄金评测集的学习者话语，分别提交给两个条件：条件 A 是扮演采购经理的通用大模型，条件 B 是接入语料库的完整产品。每条输入产生一组输出，共 40 组样本。

实验要素	设置
自变量	是否使用语料库增强（条件 A 不使用，条件 B 使用）
因变量	四维量表得分、诊断准确率、引用有效率
控制变量	相同的任务背景、相同的模型与版本、相同的人物设定、相同的输入文本
样本量	20 条输入乘以 2 个条件，共 40 组输出
评分	3 名评分者独立盲评，取均值

6.2 评分者与盲评

评分者包括两名印尼语母语者和一名中国籍印尼语教师。评分者不知道每组输出属于哪个条件，也不了解研究假设。正式评分前用 5 条公共样本校准，评分差异超过一个等级时先统一标准再开始。

6.3 统计方法

每条输入的两个条件构成配对样本，用 Wilcoxon 符号秩检验比较四维得分，报告效应量与置信区间。评分者之间的一致性用组内相关系数报告。样本量较小时不报告显著性以外的因果结论。

6.4 通过标准

- H1 成立：商务得体性与地道度两个维度的均值差达到 0.5 分以上，且配对检验的 p 小于 0.05。
- 两个条件得分接近时，说明语料增强没有带来可感知的差异。这一结果同样写入结题报告，并据此重新审视检索与提示词设计。

7 用户测试

7.1 被试

8 至 10 人：印尼语专业高年级学生 6 至 8 人，商务印尼语或其他印尼语课程教师 1 至 2 人。至少一半为非熟人参与者。记录被试已修课程与相关考试成绩，作为背景变量写入结果。

7.2 测试任务

1. 自由探索 5 分钟，不提供任何引导，观察第一次开口用了多久。
2. 完成预习模式下的一个任务，并说出自己认为最有用的三条表达。
3. 完成一场议价演练，至少 8 轮对话。
4. 查看复盘报告，指出一条自己认同的诊断与一条不认同的诊断。
5. 填写问卷并回答三个开放问题。

7.3 观察记录

观察项	记录方式
首次开口之前的停留时间	秒表记录
会话完成率与对话轮次	系统日志
卡住的位置与原因	观察表，记录轮次与操作
参考表达的使用次数	系统日志
对诊断的反应（认同、质疑、忽略）	出声思维记录

7.4 问卷

五个五级李克特题项加三个开放题。题项为：表达是否更符合商务场景；是否能看出反馈的依据；是否愿意继续使用；难度是否合适；是否愿意推荐给同学。开放题为你认为最有用的一点、最想删掉的一点、希望增加的一点。

7.5 伦理与数据处理

测试前取得知情同意，说明数据用途与匿名化处理方式，录音与录屏需要单独取得同意。原始记录只保留在研究目录内，公开发表和结题材料中只呈现匿名化片段。

8 结果汇报

8.1 结果记录表

指标	目标	实测	结论
会话完成率	不低于 60%	待填	待填
检索命中率	不低于 0.80	待填	待填
诊断误报率	不高于 0.10	待填	待填
表达质量均分	不低于 3.0	待填	待填
H1 得体性与地道度得分差	不低于 0.5	待填	待填
使用意愿	不低于 70%	待填	待填

8.2 结论的写法

- 报告被试数量与背景，说明结论适用的范围，不做超出样本的推断。
- 区分三类证据强度：检索层与生成层可以给出准确率；效果层只能给出初步证据。
- 如实报告未达标的指标与原因，不做选择性呈现。

8.3 归档结构

建议目录为：语料核对报告、黄金评测集（含版本号与标注文件）、对照实验原始评分、用户测试记录、指标计算脚本。所有文件命名包含日期与版本号，便于结题时追溯。

附录 A 判定规则与边界案例

情形	判定
语法正确但用词不地道	语法与词形记 4 分，地道度扣 1 分
同一偏误在同一场对话中反复出现	每条独立计分，另在复盘中标记为高频偏误
中文夹印尼语	该轮任务推进记 1 分，并在诊断中标记为语言选择问题
句子得体但信息错误，例如报错价格	得体性正常计分，任务推进扣分
系统给出两条诊断，其中一条是误报	该条目按误报计入，不做折中
口语化缩写，例如用 pak 代替 Bapak	按场景判定，正式谈判情境中扣 1 分
学习者照抄参考表达	该轮标记为依赖，不计入表达质量提升的统计

情形	判定
检索返回其他阶段的语料但语境相关	计为命中，同时计入阶段过滤准确率的失败
两名评分者分歧达到两个等级	该条目提交裁决，不取平均值
无法确定是否存在偏误	标注为存疑，不计入命中率分母，单独报告数量

附录 B 评测时间安排

阶段	时间	产出
黄金评测集构建与冻结	第 2 至 3 周	冻结版本数据集与一致性报告
检索层评测	第 3 周	检索命中率与阶段过滤准确率
对照实验	第 4 周	40 组输出的盲评结果
用户测试	第 4 周	测试记录、问卷与开放题编码
结果汇总	第 4 周末	结果记录表与结论草稿